

En la fase de Análisis Exploratorio de Datos (EDA) realizado sobre los cuatro archivos proporcionados, se identificaron diversas inconsistencias y errores que podrían afectar la calidad de los análisis posteriores y el rendimiento de los modelos predictivos. Para garantizar la integridad de los datos, se aplicaron las siguientes técnicas de limpieza y transformación:

Tratamiento de valores atípicos (outliers) negativos:

Mediante la utilización de diagramas de caja (box plots), se detectó la presencia de valores atípicos negativos en la columna correspondiente a los "tiempos de respuesta". Dado que estos valores no son lógicos en este contexto (un tiempo de respuesta no debería ser negativo) y sesgan negativamente el cálculo de promedios y otras métricas, se procedió a filtrar el conjunto de datos, eliminando estos registros para obtener una distribución más realista.

Estandarización del formato de fechas:

Se observó que las columnas de fecha no contaban con un formato uniforme, lo cual es un requisito fundamental para trabajar con series temporales y realizar forecast en Python. Por esta razón, se convirtieron todas las fechas al formato datetime estándar, lo que permite ordenarlas correctamente y realizar operaciones como el cálculo de diferencias entre fechas o la creación de variables temporales (día de la semana, mes, etc.).

Eliminación de registros duplicados:

Se encontraron múltiples filas duplicadas, es decir, registros idénticos en todas sus columnas. Esta redundancia no aporta información valiosa y puede distorsionar los análisis. Por lo tanto, se identificaron y eliminaron estos registros para trabajar únicamente con datos únicos y representativos.

Manejo de valores nulos (NULL):

Se identificaron valores faltantes en algunas columnas. Dado que estos representaban menos del 1% del total de los datos, se optó por imputarlos utilizando el promedio de la columna correspondiente. Esta técnica es adecuada cuando el porcentaje de nulos es muy bajo, ya que no altera significativamente la distribución original de los datos y permite conservar el volumen de información para el análisis.

Homologación de categorías:

Se detectó que una misma categoría estaba ingresada de diferentes maneras entre los distintos archivos como, por ejemplo: mayúsculas/minúsculas, abreviaturas, errores tipográficos y espacios en blanco. Para asegurar la consistencia y permitir la correcta integración de las bases de datos, se unificaron estos criterios, homologando todas las categorías a un mismo formato y nomenclatura estándar.